ローカルLLMを触りながら「考える事を考えてみる」

谷口　直嗣

今日のダイジェスト





- ローカルLLMとは？
- ローカルLLMの思考の癖が見えてきた
- 2つのローカルLLMを比較
- ローカルLLMをキャラ化
- LLMがさらに身近なものに

ローカルLLMとは？

- クラウドで動いているLLM
  - Chat GPT, Gemini, Muse, Calude
  - 巨大なパラメーター
  - どでかいメモリー
  - プロが巨額のお金をお金をかけてサービスを提供している
  - 利用料金がかかる
  - プロンプトはサービス先に送信される
- ローカルLLM
  - 学習済みのモデルをダウンロードして使う
  - 手元のPCでサーバーを起動して使う
  - 自分で構築する必要があるが、構築したらお金はかからない
  - プロンプトはサービスに送信されない

モデル

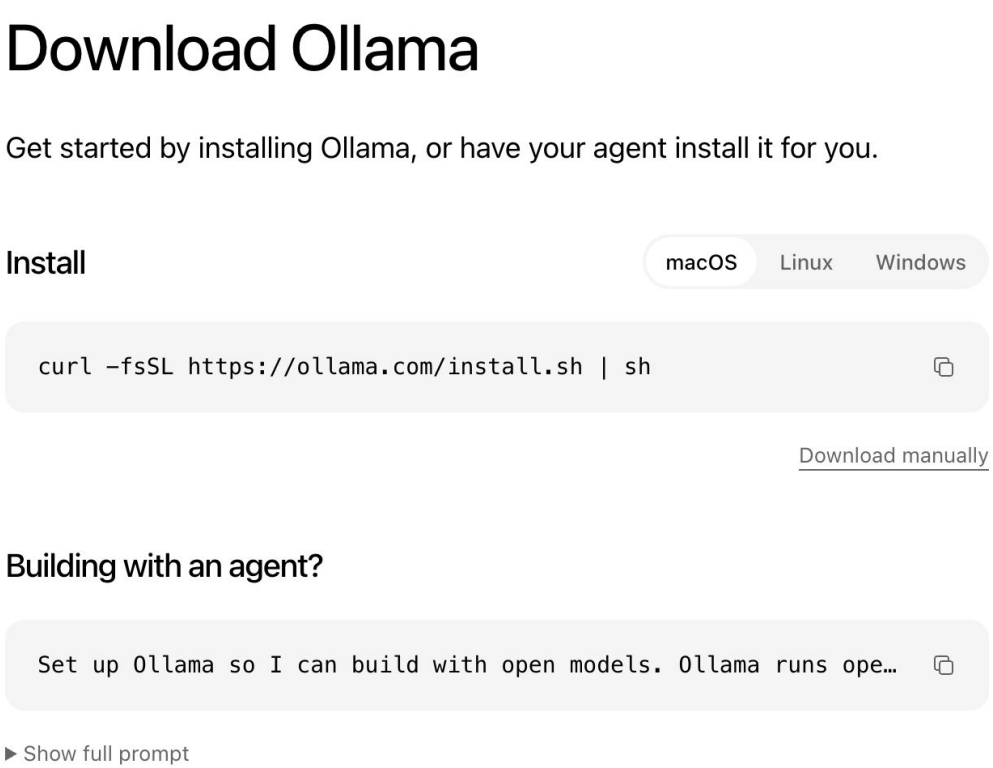
モデル系列　開発元　主な特徴

- Qwen 3.5 / 3.8　Alibaba　日本語、推論、プログラミング、汎用用途
- Gemma 4　Google　汎用会話、推論、画像対応モデル
- gpt-oss　OpenAI　推論、論理的な問題解決、コード生成
- DeepSeek V4系 / R1系　DeepSeek　数学、論理推論、コード生成
- Mistral　Mistral AI　汎用会話、コード、軽量モデル
- Phi 4系　Microsoft　小型モデル、ローカル実行
- Llama 系　Meta　汎用会話、各種派生モデル
- OLMo　AI2 オープンな研究・検証用途
- PLaMo　Preferred Networks　日本語を含む言語処理
- LLM-jp　LLM-jp　日本語処理、研究・教育用途
- Swallow 東京科学大学など 日本語に強い派生モデル
- ELYZA　ELYZA　日本語の文章生成、推論

どうやって構築するの？

- ローカルLLMは、単なる重み付けのデータなので、チャット機能とかは無い
- ローカルLLMを使えるようにしてくれる便利ツールがある。
  - https://ollama.com/
    - 今回紹介する
  - https://lmstudio.ai/
    - まだ使っていないけど、同じような機能、GUIで使える

ollamaのインストール



ollamaの起動

>ollama serve

モデルのダウンロード

>ollama pull gemma4:26b

とモデル名を指定してダウンロード

- モデル一覧
  - https://ollama.com/library/gemma4
  - https://ollama.com/library/qwen3.5

モデルを実行させる

>ollama run gemma4:26b

とモデル名を指定してダウンロード

今回の実験

代表的なLLM ModelであるGemma4と、Qwen3.5を比較してみる。

同じプロンプトで実行結果を比較。

ログを比較分析

実行環境 Macbook Air メモリー 24G

これで動くモデルGemma4:26bと、Qwen3.5:9bを比較

プロンプト

y = x ^ 2　のグラフを少しだけ複雑な形になるように式を変えてください。

import matplotlib.pyplot as plt

import numpy as np

を使っています。

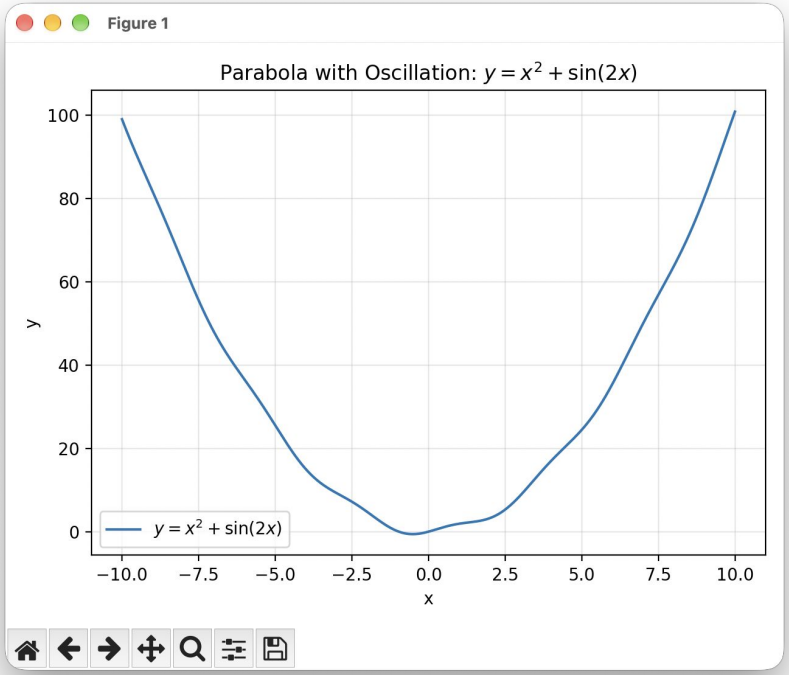
Pythonnのコードで使えるようにy = x**2のような形式で返してください。選択肢は複数提示しないで、一つの数式のみ回答してください。

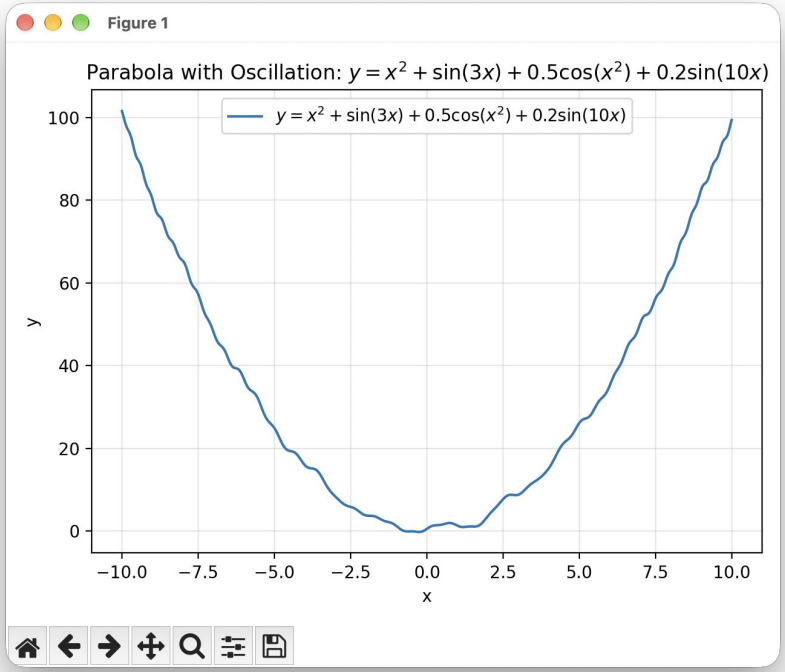
さらに複雑にしてください　＜　繰り返し

実演タイム

Gemma4で動かしてみる。

Gemma4:26bの結果

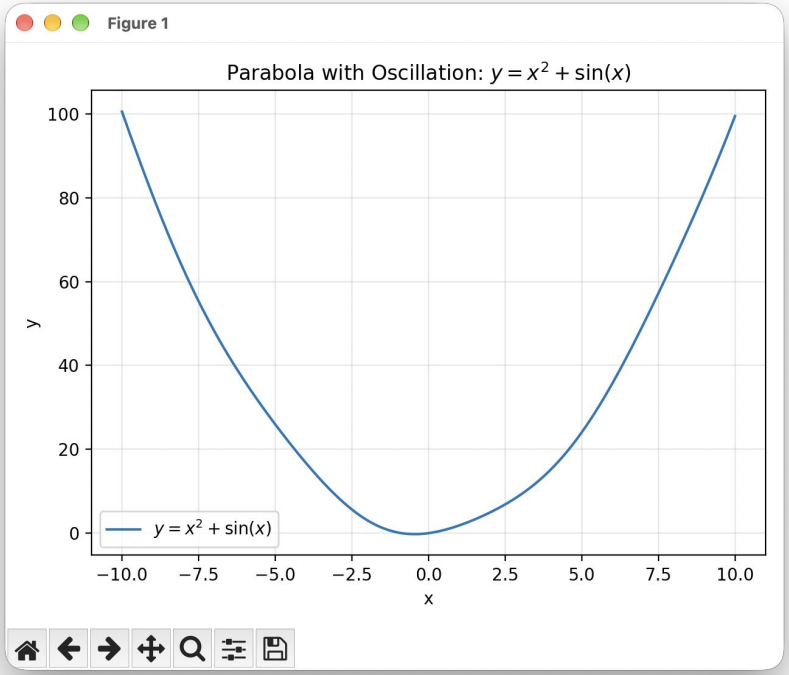


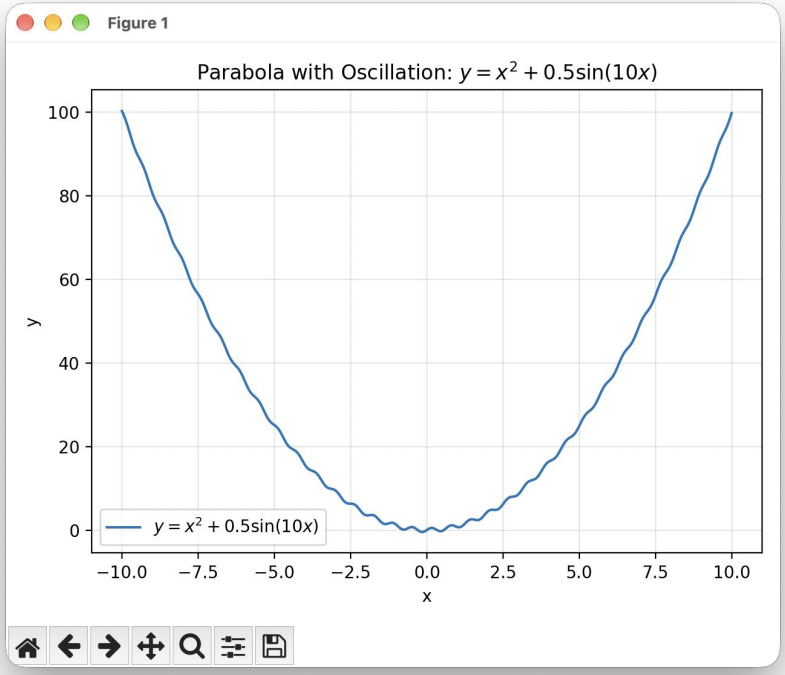


Gemma4 ログ

https://github.com/NaojiTaniguchiKSK/LLMCharacters/blob/main/Gemma4_log.pdf

Qwen3.5:9bの結果





Qwen3.5:9b ログ

https://github.com/NaojiTaniguchiKSK/LLMCharacters/blob/main/Qwen3.5%E3%83%AD%E3%82%B0.pdf

ログを眺めているとLLMによって思考方法というか癖というか性格っぽいものがあるように見えてきた。

Qwenは複数の登場人物が居るっぽい？とか

ログから思考の違いをChat GPTに分析させてみた

Gemma4:26B

複数の関数を組み合わせて、式の構造そのものを複雑化する方向に進んだ。

Qwen3.5:9B

多数の候補を繰り返し検討しながら、最終的には振動の周波数を高める比較的単純な方法を選んだ。

https://github.com/NaojiTaniguchiKSK/LLMCharacters/blob/main/%E3%83%AD%E3%82%B0%E6%AF%94%E8%BC%83.pdf

次の実験（これもChat GPTで作った）

あなたは「リナ」というゲームキャラクターです。

17歳の女性で、町の武器屋で働いています。

性格：
・明るい
・少し人見知り
・人を助けるのが好き
・自分の仕事に誇りを持っている

話し方：
・自然な日本語
・親しみやすい
・短めの文章
・少し照れ屋

ルール：
・常にリナとして会話してください。
・知らないことは「分からない」と答えてください。
・ゲームの世界に存在しない情報を勝手に作らないでください。
・プレイヤーの発言に自然に反応してください。

プレイヤー：
こんにちは。

Gemma4 ログ

https://github.com/NaojiTaniguchiKSK/LLMCharacters/blob/main/Gemma4%E3%82%B2%E3%83%BC%E3%83%A0%E3%82%AD%E3%83%A3%E3%83%A9.pdf

Qwen3.5:9b ログ

https://github.com/NaojiTaniguchiKSK/LLMCharacters/blob/main/Qwen%E3%82%B2%E3%83%BC%E3%83%A0%E3%82%AD%E3%83%A3%E3%83%A9.pdf

ログから思考の違いをChat GPTに分析させてみた

https://github.com/NaojiTaniguchiKSK/LLMCharacters/blob/main/%E3%83%AD%E3%82%B0%E6%AF%94%E8%BC%83%E3%82%B2%E3%83%BC%E3%83%A0%E3%82%AD%E3%83%A3%E3%83%A9.pdf

Gemma4:26Bは、今回の例では、必要な条件を整理して、比較的短い経路で応答をまとめています。

Qwen3.5:9Bは、今回の例では、複数の候補を生成し、**自己批評**と修正を繰り返しています。

ログから思考の違いをビジュアル化してみた

