Gemma 4:26B と Qwen3.5:9B の思考ログ比較

今回のログからは、両モデルとも「放物線 $y = x^2$ に三角関数を加えて形を複雑にする」という基本方針を採用しています。しかし、候補の探索方法、複雑さの評価基準、最終回答を決めるまでの振る舞いには、はっきりした違いが見られます。

特に興味深いのは、Gemmaが最初の回答で複数の候補を検討しながら選択を何度も変更するのに対し、Qwenは最初の回答では比較的早く方針を固め、2回目では候補の探索を長く続けている点です。

なお、ここで比較できるのは、Ollamaが表示した思考ログと最終出力に現れた振る舞いです。ログだけでモデル内部の実際の認知過程を直接観察できるわけではありません。

1. 最終回答の比較

Gemma4:26B

1回目

y = x**2 + np.sin(x * 2)

2回目

y = x**2 + np.sin(x * 3) + 0.5 * np.cos(x**2) + 0.2 * np.sin(x * 10)

Qwen3.5:9B

1回目

y = x**2 + np.sin(x)

2回目

y = x**2 + 0.5 * np.sin(10*x)

この結果から分かるのは、Gemmaが2回目に複数の周波数成分と x^2 を引数にした余弦関数を組み合わせたのに対し、Qwenは最終的に高周波の正弦波を1つ加える方式を選んだことです。

ただし、式の複雑さとモデルの思考能力は同じではありません。より複雑な式が、必ずしも要求に対するより良い回答とは限りません。

2. 思考方法の違い

Gemma4:26B — 候補を列挙し、段階的に組み合わせる

Gemmaは、最初に複数の方針を列挙し、そこから具体的な式を選ぶ方法を取っています。

- 多項式、三角関数、複数の波の合成などを検討する。
- 「波形が見えるか」「複雑すぎないか」といった基準で候補を比較する。
- 一度選んだ式を再検討し、係数や周波数を変更する。
- 最後にPythonのコードとして使えるか確認する。

特徴: 候補の探索から組み合わせの設計まで進める傾向があります。2回目は、単に波の数を増やすだけでなく、`np.cos(x**2)` によって位置によって波の細かさが変化する構造を取り入れました。

Qwen3.5:9B — 多数の候補を試し、条件を繰り返し確認する

Qwenも候補を列挙しますが、特に2回目では、同じ候補や類似した候補を何度も再検討しています。

- 加算、乗算、周波数変更、指数関数など、幅広い方法を挙げる。
- 「複雑さ」と「元の放物線の形を保つこと」のバランスを考える。
- 元の指示に立ち返り、数式を1つだけ返すという制約を繰り返し確認する。
- 最終的に、比較的単純な高周波の正弦波を加える式に戻る。

特徴: 探索範囲は広いものの、検討の重複が多く、候補を絞り込むまでに時間がかかっています。

重要なのは、Qwenのほうが候補を多く列挙しているからといって、必ずしも探索が効果的とは限らないことです。同じ候補を繰り返すことは、探索量の増加にはなっても、判断の改善にはつながらない場合があります。

3. 2回目の応答から見える違い

「さらに複雑にしてください」という追加指示に対する挙動は、特に比較しやすい部分です。

比較項目	**Gemma4:26B**	**Qwen3.5:9B**
複雑さの増やし方	異なる種類の関数を合成	主に波の周波数や振幅を調整

最終式の構造	多項式＋3つの周期成分	多項式＋1つの周期成分
元の式との関係	放物線に複数の変動を追加	放物線に細かい振動を追加
候補の再検討	多い	非常に多い
指示の再確認	最後に出力形式を確認	出力制約を何度も確認
思考の収束	比較的複雑な式に収束	単一の高周波項に収束

Gemmaは「関数の構造」を複雑にした

Gemmaの最終式は次の構造です。

$$y = x^2 + \sin(3x) + 0.5\cos(x^2) + 0.2\sin(10x)$$

それぞれの項には異なる役割があります。

- x^2：全体の放物線の形を決める。
- $\sin(3x)$：一定の周期で振動を加える。
- $\cos(x^2)$：x の絶対値が大きくなるほど振動が細かくなる。
- $0.2\sin(10x)$：細かな振動を重ねる。

つまり、複数の種類の変化を組み合わせています。

Qwenは「振動の密度」を増やした

Qwenの最終式は次のとおりです。

$$y = x^2 + 0.5\sin(10x)$$

こちらは放物線の基本構造を維持したまま、振動の周波数を上げています。最初の回答からの変化としては、振動をより細かくするという一貫した方向性があります。

ただし、Qwenの思考ログでは、振幅変調や指数関数を使う案なども検討されていました。最終的に単純な式に戻ったことは、探索の幅と最終回答の複雑さが必ずしも比例しないことを示しています。

4. 両モデルに共通する課題

今回のログには、両モデルに共通する特徴もあります。

① 最初の指示を守ることと、思考中の振る舞いは別

両モデルとも最終回答では数式を1つだけ返しています。一方、思考ログでは複数の候補を列挙しています。

これは必ずしも指示違反ではありません。ユーザーが制限していたのは回答の形式であり、内部の候補検討ではないためです。ただし、思考ログが長くなるほど、指示の再確認に費やす量も増えています。

② 自己修正を繰り返しても、判断が必ず改善するわけではない

Gemmaは最終候補を何度も変更しています。Qwenも同様ですが、特に2回目は、同じような式を繰り返し比較しています。

自己修正は有用ですが、明確な評価基準がなければ、検討を繰り返すだけになりがちです。

③ 数学的な検証と、見た目の評価は異なる

両モデルとも「視覚的に面白いか」「元の形を維持できるか」を考えていますが、ログには実際にグラフを描画して確認した証拠はありません。

そのため、今回の「複雑さ」は主に言語的な推論による評価です。実際のグラフの見た目を評価した結果とは区別する必要があります。

5. 思考ログの長さは、思考能力を表すのか？

ここは特に重要です。

今回のログではQwenの思考過程が非常に長く、同じ候補を繰り返し検討しています。一方、Gemmaは比較的短いログで、複数の関数を組み合わせた式に到達しています。

しかし、次の3つは区別する必要があります。

- 探索量: どれだけ多くの候補や可能性を挙げたか。
- 判断の質: 要求に合った候補をどれだけ適切に選べたか。
- 効率: どれだけ少ない計算や時間で適切な結果を出せたか。

今回のログからは、Qwenが探索量の多い振る舞いを示し、Gemmaがより複合的な最終式を選んだことは確認できます。しかし、ログの長さだけで、どちらのモデルが本質的に優れた推論をしているかは判断できません。

また、Ollamaのバージョン、モデルの量子化方式、推論設定、思考トークンの上限などが統一されているかは、このログからは分かりません。

6. 今回の実験から得られる結論

今回の結果を、あえて簡潔にまとめると次のようになります。

Gemma4:26B

複数の関数を組み合わせて、式の構造そのものを複雑化する方向に進んだ。

Qwen3.5:9B

多数の候補を繰り返し検討しながら、最終的には振動の周波数を高める比較的単純な方法を選んだ。

ただし、これは今回のプロンプトと2回の応答に限定した観察です。モデル全体の一般的な性質と断定するには、追加実験が必要です。

次に行うと面白い実験

この比較を研究や授業の題材として発展させるなら、次の3つを試すと違いをより明確にできます。

1. 同じ条件で10〜20回ずつ実行する。最終式の複雑さ、候補の重複数、出力までの時間を記録する。
2. 複雑さの基準を指定する。例えば「三角関数を2種類以上使う」「元の放物線の大まかな形を維持する」と指定し、指示への適合率を比較する。
3. 生成した式を実際にグラフ化する。目視評価や数値的な特徴量を使って、思考ログで述べた「複雑さ」と実際の出力が一致するか調べる。

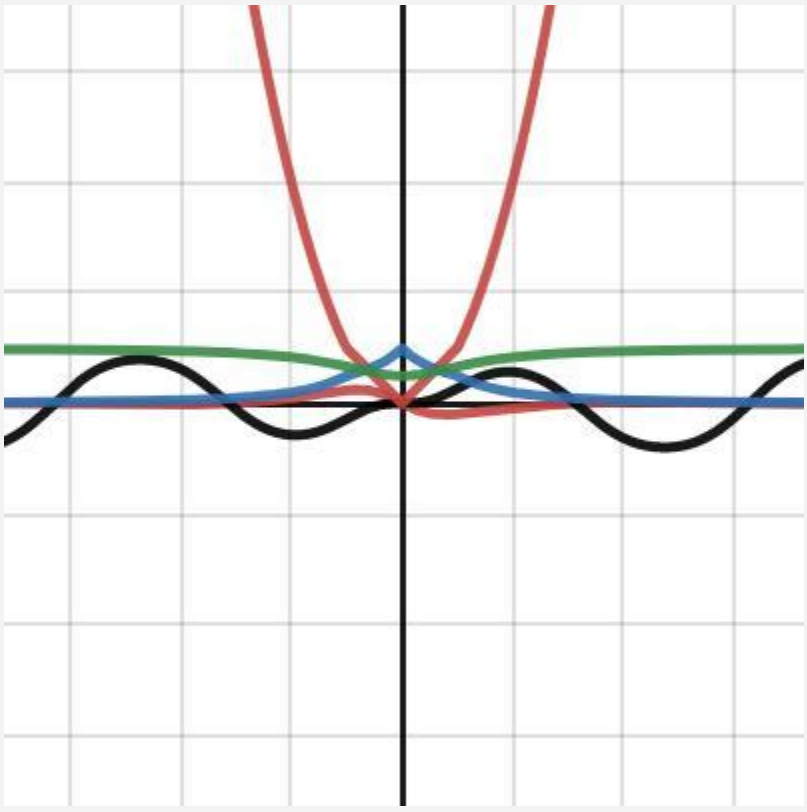
特に3番目は重要です。AIが「複雑な形になる」と説明したことと、実際に複雑な形を生成できたことを分離して評価できるからです。

このログの違いから、Gemma4 と Qwen3.5 の設計思想の違いを分析する事はできますか？

はい、分析できます。ただし、今回のログから分かるのは、厳密には Gemma4 と Qwen3.5 の「設計思想そのもの」ではなく、設計思想が出力にどう表れている可能性があるか です。内部の学習方法や設計意図をログだけから断定することはできません。

今回の実験は、両モデルに同じ課題を与え、数式を段階的に複雑化させたものです。この条件では、最終的な数式だけでなく、候補の検討方法、制約の扱い、複雑さの増やし方に違いが現れています。

1. ログから読み取れる主な違い



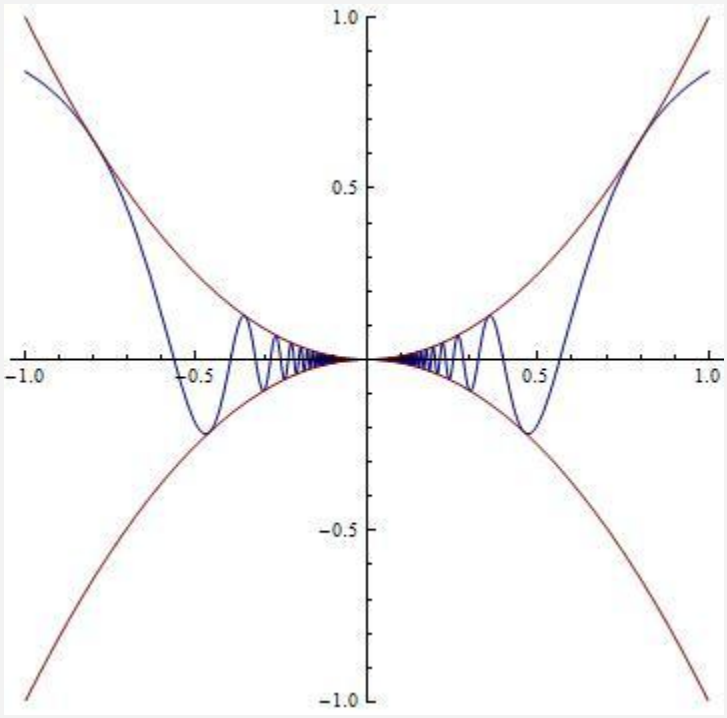
Gemma4：複数の要素を組み合わせる方向

ログからの観察

- 最初は放物線に正弦波を加えた式を選ぶ。

- 追加の複雑化では、正弦波に加えて、
- x2
- x
- 2
- を入力とする余弦波や高周波の正弦波も組み合わせる。
- 候補を検討しながら、式の構成を段階的に変更している。

考えられる傾向: 複雑さを、異なる種類の要素を重ねることで表現しようとする。



Qwen3.5:候補を広く検討してから選ぶ方向

ログからの観察

- 長い思考ログの中で、多数の候補や数式の組み合わせを検討する。
- 2回目には、振幅・周波数・複数の関数の組み合わせなどを考慮する。
- それでも最終的には、比較的単純な高周波の正弦波を加えた式を選ぶ。

考えられる傾向: 候補の探索範囲は広い一方、最終出力では構造を絞り込む。

ここで重要なのは、Qwen3.5のほうが思考ログが長いからといって、必ずしも深く考えているとは限らないことです。候補を多く挙げることと、最適な式を見つけることは別の能力です。

2. 設計思想との対応を考える

公開されているモデルの技術情報と今回のログを照らし合わせると、次のように整理できます。

観点	Gemma4:26B	Qwen3.5:9B
公開情報から分かる開発上の重点	推論、コーディング、マルチモーダル処理、エージェント機能	推論、コーディング、マルチモーダル処理、エージェント機能と効率性
今回のログに見える特徴	関数の種類を増やして数式の構造を複雑化	多数の候補を検討した後、比較的単純な式を選択
推測される問題解決の傾向	構造を組み立てる探索	候補を広く探索して絞り込む動き
このログだけで設計思想と断定できるか	できない	できない

Googleの公式資料では、Gemma4は推論モードを備え、コーディングやエージェント型の処理にも対応するモデルファミリーとして説明されています。【turn298548search0】

一方、Qwen3.5の公式発表では、推論・コーディング・エージェント機能に加えて、推論効率やマルチモーダル処理を重視した設計が説明されています。【turn311915search1】

ただし、ここで注意したいのは、どちらの公式資料にも、今回観察された「構造を組み立てる型」と「広く探索して絞り込む型」の違いが、モデル固有の設計方針だと示されているわけではないことです。表の後半は、あくまで今回のログから立てられる仮説です。

3. なぜ、このような違いが生まれた可能性があるのか

今回のログには、少なくとも3つの説明候補があります。

仮説A：学習・調整方法の違い

モデルが「良い回答」をどのようなものとして学習してきたかによって、候補をたくさん検討する傾向や、回答を早くまとめる傾向が変わる可能性があります。

ただし、今回のログだけでは、その違いが事前学習、事後学習、推論時の制御のどこから生じたのかは分かりません。

仮説B：推論モードや生成設定の違い

思考モードの有効・無効、生成トークンの上限、温度などが異なれば、ログの長さや候補の多さも変わります。
Gemma4には思考モードの制御方法があり、Qwen3.5にも思考モードがあります。【turn298548search0】【turn311915search2】したがって、同じプロンプトだけでは公平な比較にならない可能性があります。
仮説C：モデル規模や実行環境の違い
今回は26Bと9Bという異なる規模のモデルを比較しています。加えて、量子化方式、Ollamaのモデル定義、チャットテンプレートなども結果に影響し得ます。
そのため、観察された違いをモデルの設計思想だけに帰属させることはできません。

4. 研究として確かめるには

この比較を、単なる印象ではなく「ローカルLLMの問題解決傾向の比較研究」として発展させるなら、次の実験が有効です。

実験	観察する項目	検証できること
同じ課題を20回ずつ実行	思考トークン数、候補数、回答時間	傾向が安定して現れるか
「複雑に」の意味を指定	使用関数の種類、項の数、周波数	数式の複雑さをどう解釈するか
数式の実際のグラフを描画	見た目の変化、振幅、振動数	説明上の複雑さと結果の複雑さが一致するか
思考モードや生成設定を揃える	回答品質、探索量、反復数	設定差による影響を減らせるか
別の課題でも比較する	コード生成、デザイン案、文章構成など	数式課題だけの特徴か、より広い傾向か

特に重要なのは、「思考ログの長さ」と「成果の質」を別々に評価することです。今回のQwen3.5は候補を多く検討していますが、最終的な式はGemma4より単純でした。これは、探索量が多いことと、最終成果が複雑であることは別だという具体例になっています。

結論

現時点での私の解釈は、次のとおりです。

- Gemma4： 今回の課題では、複数の関数を組み合わせて数式の構造を発展させる傾向が見られた。

- Qwen3.5：今回の課題では、広い候補探索を行いながら、最終的な回答は比較的単純な構造にまとめる傾向が見られた。

これは興味深い観察ですが、まだ「設計思想の違いが証明された」とはいえません。今後の実験で同じ傾向が複数の課題や設定でも再現されれば、モデルごとの問題解決スタイルを比較するための有力な仮説になります。

なお、今回のログに現れた検討過程は、モデルが生成したテキストとして観察できるものです。それを人間の内省と同じ意味での思考や、内部処理の完全な記録とみなさないことも、研究上の重要な注意点です。