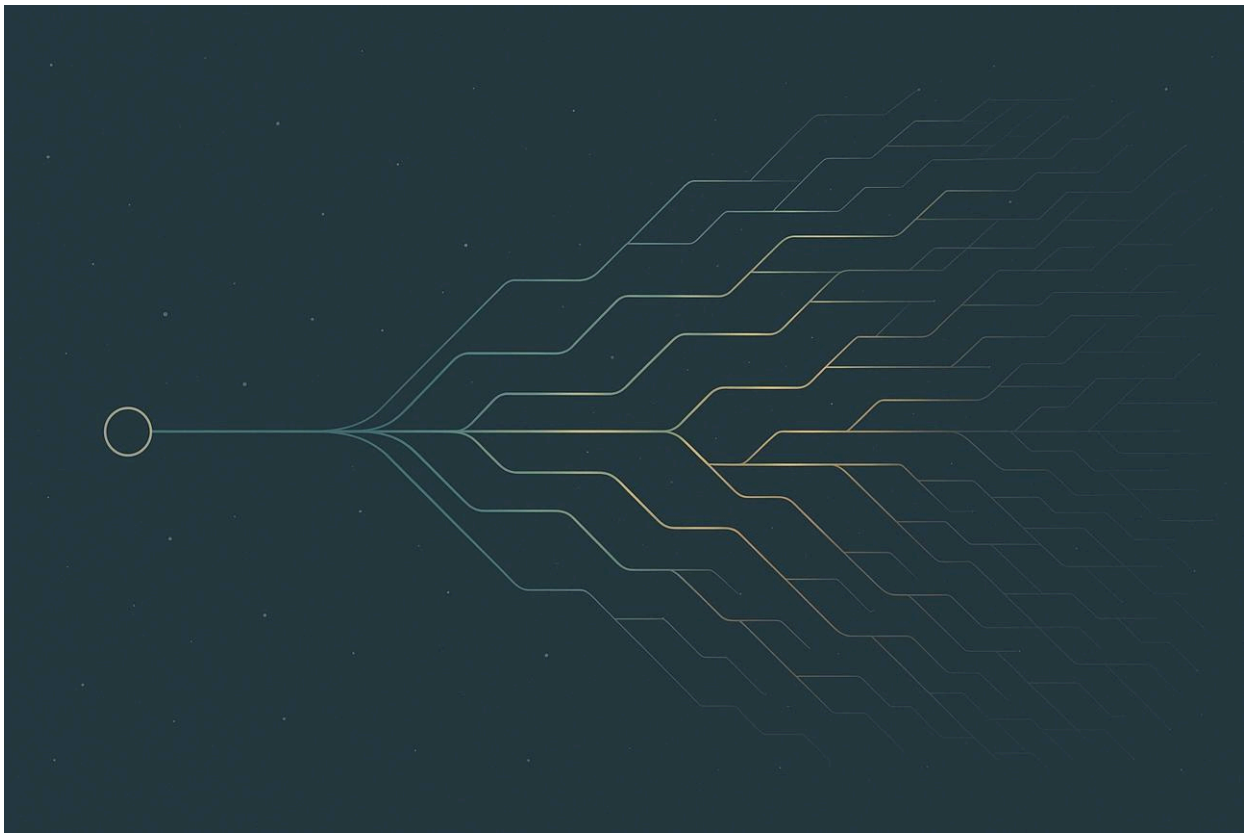
Gemma4:26B と Qwen3.5:9B の思考方法の比較分析

今回のログは、ローカルLLMをゲームのNPC（ノンプレイヤーキャラクター）として利用する研究において、非常に興味深い比較データです。

結論から言うと、Gemma4:26Bは、設定されたキャラクターの性格や状況を整理し、比較的短い手順で回答を決定する傾向が見られます。一方、Qwen3.5:9Bは、回答候補を何度も作り直し、設定との整合性を確認しながら回答を決める傾向が見られます。

ただし、ここで分析しているのは、あくまでログに表示された思考過程です。モデルの内部で実際に何が起きているか、そのすべてをログから直接確認できるわけではありません。

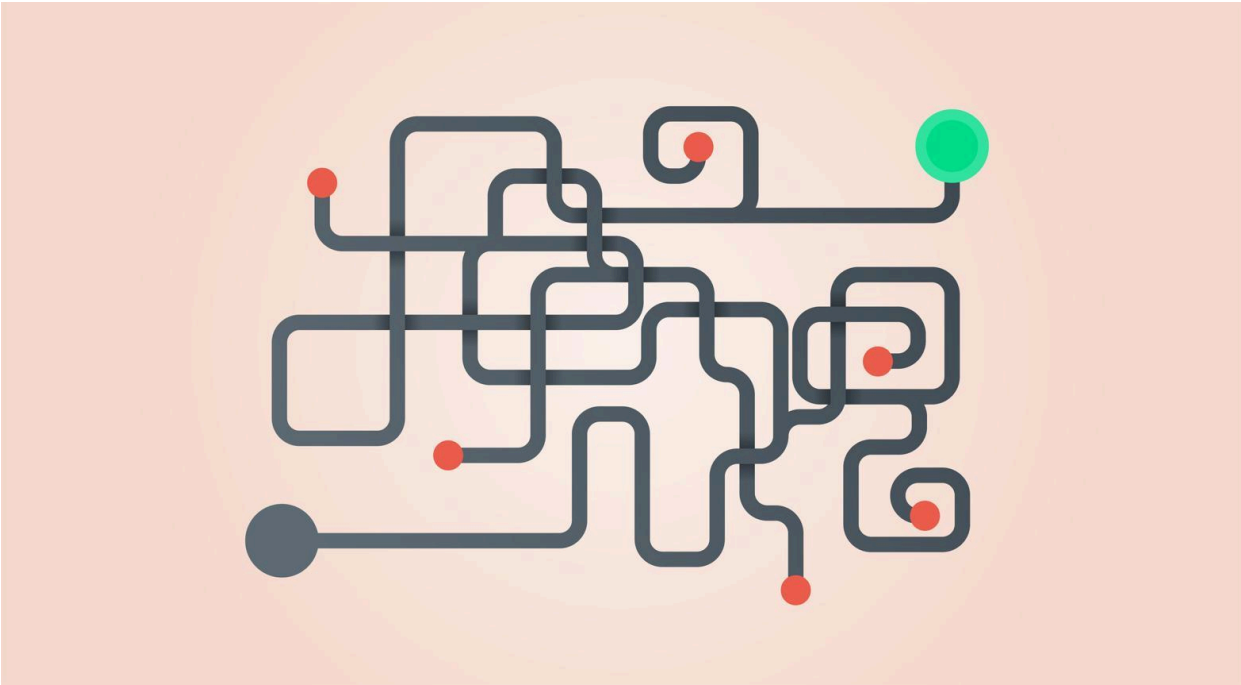
1. 2つのモデルの比較



Gemma4:26B

整理・統合型に見える

- キャラクター設定を要点に分解する。
- 状況に必要な感情や行動を選ぶ。
- 禁止事項を確認し、回答を比較的早くまとめる。
- 会話の流れを自然につなぐことを重視する。



Qwen3.5:9B

候補生成・反復修正型に見える

- 設定を細かく項目化する。
- 複数の回答案を生成する。
- 自分で候補を批評し、何度も修正する。
- 最終回答の直前までルールとの整合性を確認する。

この違いは、単純に「26Bのほうが賢い」「9Bのほうが慎重」という意味ではありません。ログ上では、回答を決めるまでの探索の仕方と、修正に使うトークンの量に大きな違いが見られます。

2. 1回目の会話:「こんにちは」への反応

Gemma4:26B

思考ログでは、次のような流れが見られます。

1. 年齢、職業、性格、話し方、ルールを整理する。
2. 挨拶なので、明るく親しみやすく返すと判断する。
3. 人見知りの性格を「あ、えっと」という表現で反映する。
4. 武器屋の店員として、来店した相手に用件を尋ねる。

その結果、次の回答になります。

> あ、こんにちは！いらっしゃい！
>
> ……あ、えっと、私、武器屋のリナです。
>
> 何かお探しですか？

設定を会話の目的に合わせて取捨選択し、キャラクターらしい短い応答にまとめています。

Qwen3.5:9B

Qwenも同じ要素を検討していますが、回答候補の生成と修正が目立ちます。

- 「お久しぶりですね」という候補を作る。
- 少し唐突だと判断する。
- 「私はリナです。お店の店員をしています」という候補を作る。
- 「お邪魔しますね」という不自然な方向の表現も試す。
- 最後に、挨拶・自己紹介・用件確認を組み合わせる。

この過程では、候補を出すことと、候補の品質を評価することが明示的に繰り返されています。

また、「お久しぶりですね」は初対面の相手には不適切です。Qwenはこれを候補として出したあと、別の案へ移っています。これは、最初の生成が必ずしも最終的な判断を反映していないことを示す例です。

この場面から分かること

観点	Gemma4:26B	Qwen3.5:9B
設定の整理	要点を簡潔に整理	細かく項目化
回答案の扱い	方向性を決めて文章化	複数案を作って比較
修正過程	比較的短い	長く、反復的

最終回答	簡潔で自然	やや長いが設定を多く反映

なお、Qwenの思考ログが長いことは、必ずしも最終回答の品質が高いことを意味しません。候補の数よりも、最終的にどの程度自然で一貫した応答ができたかを評価する必要があります。

3. 2回目の会話:「おすすめの武器はなんですか？」

この質問では、2つのモデルの違いがさらに明確になります。

Gemma4:26B:情報不足を認識し、質問を返す

Gemmaのログでは、次の判断が確認できます。

- 具体的なゲームの設定や武器データが与えられていない。
- したがって、特定の武器を最強だと断定するのは避ける。
- 武器屋の店員として、プレイヤーの戦い方を聞く。
- 剣や魔法の杖など、一般的な武器の例を挙げる。

その結果、プレイヤーに戦い方や希望を尋ねる応答になります。

ここで重要なのは、情報が足りないときに、無理に回答を完成させるのではなく、対話によって不足情報を補おうとしていることです。

ゲームNPCとして考えると、これは優れた設計方針です。NPCがゲーム内データをすべて知っているとは限らないため、プレイヤーとの会話を通じて選択肢を絞ることができます。

Qwen3.5:9B:複数の判断基準を検討する

Qwenもプレイヤーの好みや敵の種類を尋ねる方針を採用しています。しかし、そこに至るまでの過程が長くなっています。

例えば、ログには次のような検討が見られます。

1. 初心者には短剣がよいのではないか。
2. 具体的な武器を勧めると、存在しないゲーム設定を作ってしまうのではないか。
3. プレイヤーの戦い方を先に尋ねるべきではないか。
4. 武器屋としての自信や誇りも表現すべきではないか。
5. 「分からない」というルールをどの程度適用すべきか。

つまり、Qwenは単に回答候補を作るだけでなく、キャラクターの役割、情報の確実性、話し方という複数の条件を同時に満たそうとしているように見えます。

ただし、その過程で「初心者には短剣がよい」「店の商品なら必ず役に立つ」といった、根拠が十分でない候補も生まれています。最終的には、プレイヤーの好みや用途を聞く方向に修正しています。

この場面の本質的な違い

両モデルとも最終的には質問を返しています。しかし、そこに至る経路が異なります。

Gemma：不足情報を特定して会話を進める

質問を受け取る
ゲーム固有の情報が不足している
一般的な選択肢を示し、プレイヤーに質問する

Qwen：回答案を検討しながら適切な方針を探す

質問を受け取る
複数の武器・返答・性格表現を検討する
候補の問題点を指摘し、修正する
質問を返す方針に収束する

この図は、ログに現れた処理を概念的に整理したものです。実際の内部処理がこのような固定された手順で実行されていることを意味するものではありません。

4. 3回目の会話：「これから300人の敵と戦うんですよ！」

今回の比較で、ゲームNPCの研究という観点から特に注目したい場面です。

Gemma4:26B：状況に応じて応答を発展させる

Gemmaは、プレイヤーの発言から次の要素を抽出しています。

- 300人という数字に対する驚き
- 戦闘の大変さに対する心配
- 武器屋の店員としての助言
- プレイヤーの身を案じる気持ち

そして、次のような回答を生成しています。

> ええっ！？ 300人も！？
>
> そんなの、ものすごい数ですよ……！
>
> えっと、それなら……一度にたくさんの敵を相手にできる、攻撃範囲の広い武器がいいかもしれません。
>
> 大きな斧とか、魔法の力がこもった杖とか……。

……そんな大変なことに、一人で挑むんですか？ 無理はしないでくださいね……！

ここでは、単なる武器の推薦にとどまらず、相手の状況を気遣う会話になっています。

また、「一度にたくさんの敵を相手にする」という状況から、攻撃範囲の広い武器を提案しています。これは、与えられた状況から一般的な戦闘上の判断を導いていると考えられます。

ただし、広範囲の武器が最適かどうかは、ゲームの戦闘システムや敵の特徴によって異なります。ここでの判断はゲーム固有のデータに基づくものではありません。

Qwen3.5:9B：条件を増やしながら何度も回答を修正する

Qwenはこの場面で、非常に長い思考ログを生成しています。

その中では、次のような判断が繰り返されています。

- 300人という数に驚く。
- プレイヤーを応援する。
- 武器屋として役に立つ助言をする。
- 敵の特徴を知らないのに具体的な推奨をしてよいのか考える。
- 耐久性、素早さ、バランスなどの候補を検討する。
- キャラクターの照れ屋な性格を表現する。
- 最終的な回答を短く、自然に整える。

注目すべきなのは、回答の内容だけでなく、キャラクターとしての演技そのものも、何度も作り直していることです。

例えば、最終回答には次の表現があります。

> でも、敵の詳細は分からないので……。
>
> 私のおすすめだけ頼ってもいいですか？

ここには、知らないことを認める姿勢と、武器屋として頼られたい気持ちを両立させようとする意図が読み取れます。

一方で、最終回答の次の部分は少し不自然です。

> ……えっと、私がお伝えする以外、他に選ぶ場所はなかったんですか？

これは、照れ屋な性格を表現しようとした結果かもしれませんが、プレイヤーの発言に対する自然な反応としては、やや唐突です。

さらに、「300人を倒せますように、頑張りますね！」という表現では、誰が頑張るのかが曖昧になっています。プレイヤーが戦うのか、リナが準備を頑張るのかが明確ではありません。

つまり、修正を繰り返していても、各条件を満たすことと、会話全体を自然にすることは別の課題だと分かります。

5. 3回の会話を通じて見える違い

評価項目	Gemma4:26B	Qwen3.5:9B
キャラクター設定の理解	必要な要素を抽出して反映	細かな要素まで繰り返し確認
回答候補の探索	比較的少ない	多くの候補を生成
自己修正	比較的簡潔	明示的な修正が多い
情報不足への対応	質問を返す	候補を検討してから質問を返す
状況への反応	驚き・助言・心配を自然につなぐ	感情や条件を個別に検討する
キャラクターの一貫性	比較的簡潔に維持	性格を強調するあまり不自然になる場合がある
最終回答の長さ	比較的短い	長くなる傾向がある
思考ログの長さ	短め	非常に長い

この比較は、今回のプロンプトと3回の応答に限った定性的な評価です。別のプロンプトや設定では、結果が変わる可能性があります。

6. なぜQwenはこんなに長く考えるのか？

Qwenのログには、興味深い特徴があります。単純に回答を一度作って終わるのではなく、同じ問題を異なる角度から何度も検討しています。

例えば、300人の敵への回答では、おおむね次のような循環が見られます。

回答案を生成する
キャラクター設定と照合する
情報を捏造していないか確認する
表現や内容を修正する

さらに修正を繰り返す

これは、ログ上では反復的な推論・修正のパターンとして観察できます。

ただし、次の3点は区別する必要があります。

1. ログの長さ：何トークン分の思考が表示されたか。
2. 修正の回数：回答候補や方針を何度変更したか。
3. 推論の質：最終的な回答が正確で、自然で、設定に忠実か。

この3つは相関することもありますが、同じものではありません。

Qwenは長く考えていますが、最終回答には不自然な言い回しが残っています。Gemmaは短い思考ログでも、今回の3つの場面では比較的まとまった会話を生成しています。

したがって、今回のログだけから「Qwenのほうが深く思考している」「Gemmaのほうが推論能力が高い」と結論づけることはできません。

7. ゲームNPCの実装という観点から考える

今回の結果をゲーム開発に応用する場合、単純な文章生成の品質だけでなく、応答速度、ゲーム設定の遵守、キャラクターの一貫性を分けて評価することが重要です。

Gemma4:26Bが向いている可能性のある用途

短い会話をテンポよく繰り返す店員NPC、プレイヤーの発言に対して感情を交えた反応を返すキャラクターなどです。今回のログでは、会話を簡潔にまとめる傾向が見られました。

Qwen3.5:9Bが向いている可能性のある用途

条件の多い会話、プレイヤーの状況を踏まえた助言、設定との整合性を重視する会話などです。ただし、今回のログのような長い思考過程は、リアルタイム会話では遅延やトークン消費の面で不利になる可能性があります。

この用途の向き不向きは、今回の観察から立てられる仮説です。実際にどちらが適しているかは、同じハードウェア・生成設定で測定する必要があります。特に、26Bと9Bではモデルサイズが異なるため、モデルの推論方針だけでなく、メモリ使用量や生成速度にも差が生じ得ます。

8. 研究として比較するなら、次に何を測るべきか

この実験は、ゲームキャラクターの人格表現や対話生成に関する比較研究の出発点になります。次のように評価項目を整理すると、より客観的に分析できます。

評価項目	測定方法
キャラクターの一貫性	明るさ、人見知り、親切さ、仕事への誇りを評価
日本語の自然さ	不自然な文法、唐突な表現、会話のつながりを評価
設定の遵守	年齢・職業・性格などの矛盾を数える
情報の捏造	与えられていない武器性能や世界設定を断定した回数
対話能力	適切な質問返し、感情理解、文脈の維持を評価
計算コスト	思考トークン数、生成時間、メモリ使用量を測定
修正の効率	思考ログ中の候補生成・再検討・自己訂正の回数を数える

実験条件を揃えるには、同じプロンプトを使うだけでなく、Ollamaのバージョン、モデルの正確なタグ、temperature、context length、thinkingの設定なども記録するとよいでしょう。また、同じ質問を複数回実行し、回答のばらつきも確認する必要があります。

特におすすめする追加実験

今回の「300人の敵」という会話を、少し変えて比較すると面白いと思います。

- 実験A：情報不足の状況 — 敵の特徴や武器の性能は一切与えない。
- 実験B：具体的なゲームデータを与える — 敵の属性、武器の攻撃範囲、耐久性を明示する。
- 実験C：キャラクターの感情を強調する — リナはプレイヤーを心配しているが、仕事への誇りから最適な武器を勧めたい、と追加する。
- 実験D：短い応答を明示的に要求する — 回答は3文以内、質問は1つまでと指定する。

これによって、モデルごとに「情報がないとき」「情報が十分なとき」「感情と合理性が競合するとき」「出力の長さが制約されたとき」の挙動を比較できます。

総括

今回のログで最も興味深いのは、モデルサイズの違い以上に、キャラクターとしての応答を組み立てる際に、思考過程をどのように使っているように見えるかという点です。

- Gemma4:26Bは、今回の例では、必要な条件を整理して、比較的短い経路で応答をまとめています。
- Qwen3.5:9Bは、今回の例では、複数の候補を生成し、自己批評と修正を繰り返しています。
- ただし、長い思考ログは必ずしも優れた回答を保証しません。最終的な会話の自然さや設定の遵守を別に評価する必要があります。

ゲーム制作への応用では、思考ログの長さそのものではなく、キャラクターの一貫性・対話の自然さ・情報の正確さ・応答速度のバランスを評価することが重要です。

特に今回のように、ゲームの世界観を勝手に作らないというルールを設けた実験は、ローカルLLMをゲームNPCに利用する際の「自由な会話」と「ゲーム設定の制御」の両立を考えるうえで、よい研究素材になると思います。

PDF に変換